高性能消息数据存储引擎的设计解析

李淼

融云-首席架构师

融云，通信云行业领导者

李淼-融云首席架构师，联合创始人

10年IM领域设计和研究经验

安全·可靠的全球互联网通信云

通讯行业领导者

为开发者、企业提供安全、稳定、可靠

覆盖全球的通讯云服务

连续多年市场占有率稳居第一

- 实时通讯云计算平台
- 日均活跃数 6500 万
- 日消息峰值 2200 亿

TABLE OF

CONTENTS 大纲

- 即时通讯消息存储特点
- 消息存储引擎设计
- 消息存储引擎优化
- 消息存储服务架构设计

即时通讯消息存储特点

- 时间顺序进行排序
- 存储具有时效性，定期淘汰
- 写入并发量高
- 写入读取比一般在5：1

融云消息存储历程

- 原型验证-MySQL
- 正式阶段一-Redis
- 正式阶段二-LevelDB
- 正式阶段三-Redis

融云 RONGCLOUD

为什么要自研存储

- 满足复杂的数据业务逻辑
- 降低设备成本
- 简化部署模型
- 源码基本可控

存储设计要求

- 快速数据淘汰
- 避免数据合并
- 读写性能要求高
- 开发使用灵活

站在前人的肩膀

- 数据采用WAL写入
- 借鉴 InfluxDB 的 LSM 树
- 借鉴 whiskey 的 K / V 分离存储
- 借鉴 MyISAM 的文件定义

存储逻辑划分


record
record
.....
record
M_Block n
D_Block 4
D_Block 3
D_Block 2
D_Block 1
D_Block 0
Table x+n
Table x+2
Table x+1
Table x

存储文件规划

- Table
  - ✓ xxx.data 数据存储文件
  - ✓ xxx.index 数据索引文件
  - ✓ xxx.info table信息文件
- Log
  - ✓ xx.log 日志信息文件

数据写入逻辑

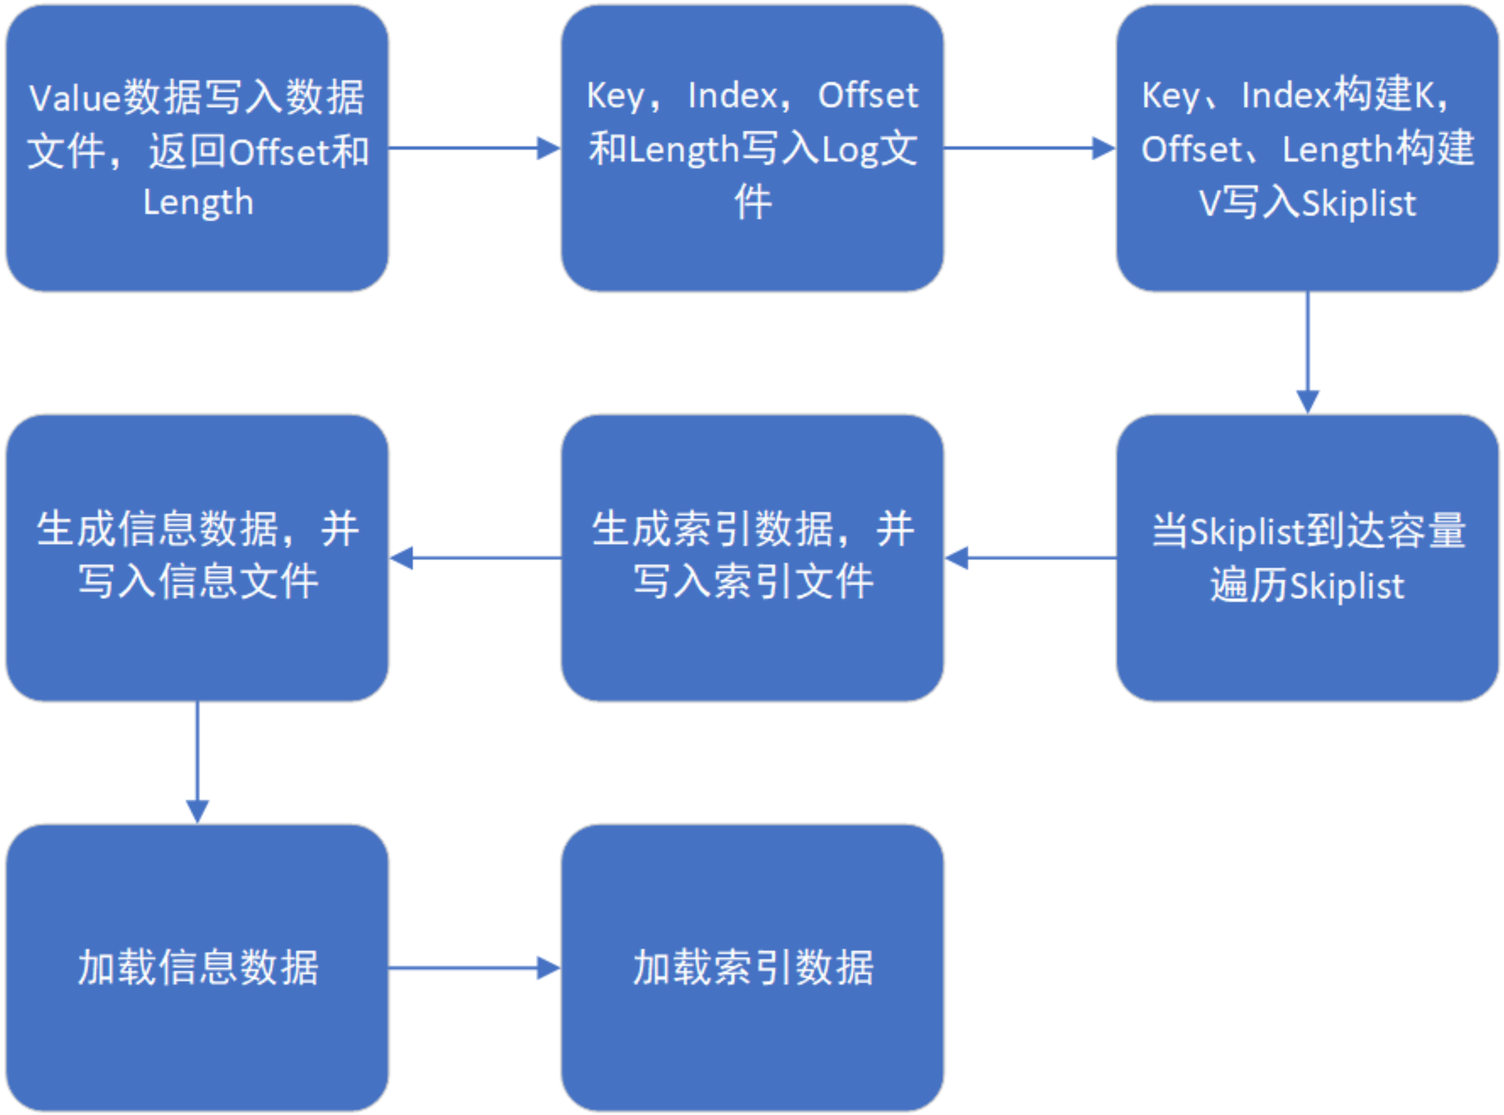
Value数据写入数据文件，返回Offset和Length
Key，Index，Offset和Length写入Log文件
Key、Index构建K，Offset、Length构建V写入Skiplist
当Skiplist到达容量遍历Skiplist
生成索引数据，并写入索引文件
生成信息数据，并写入信息文件
加载信息数据
加载索引数据

日志文件设计

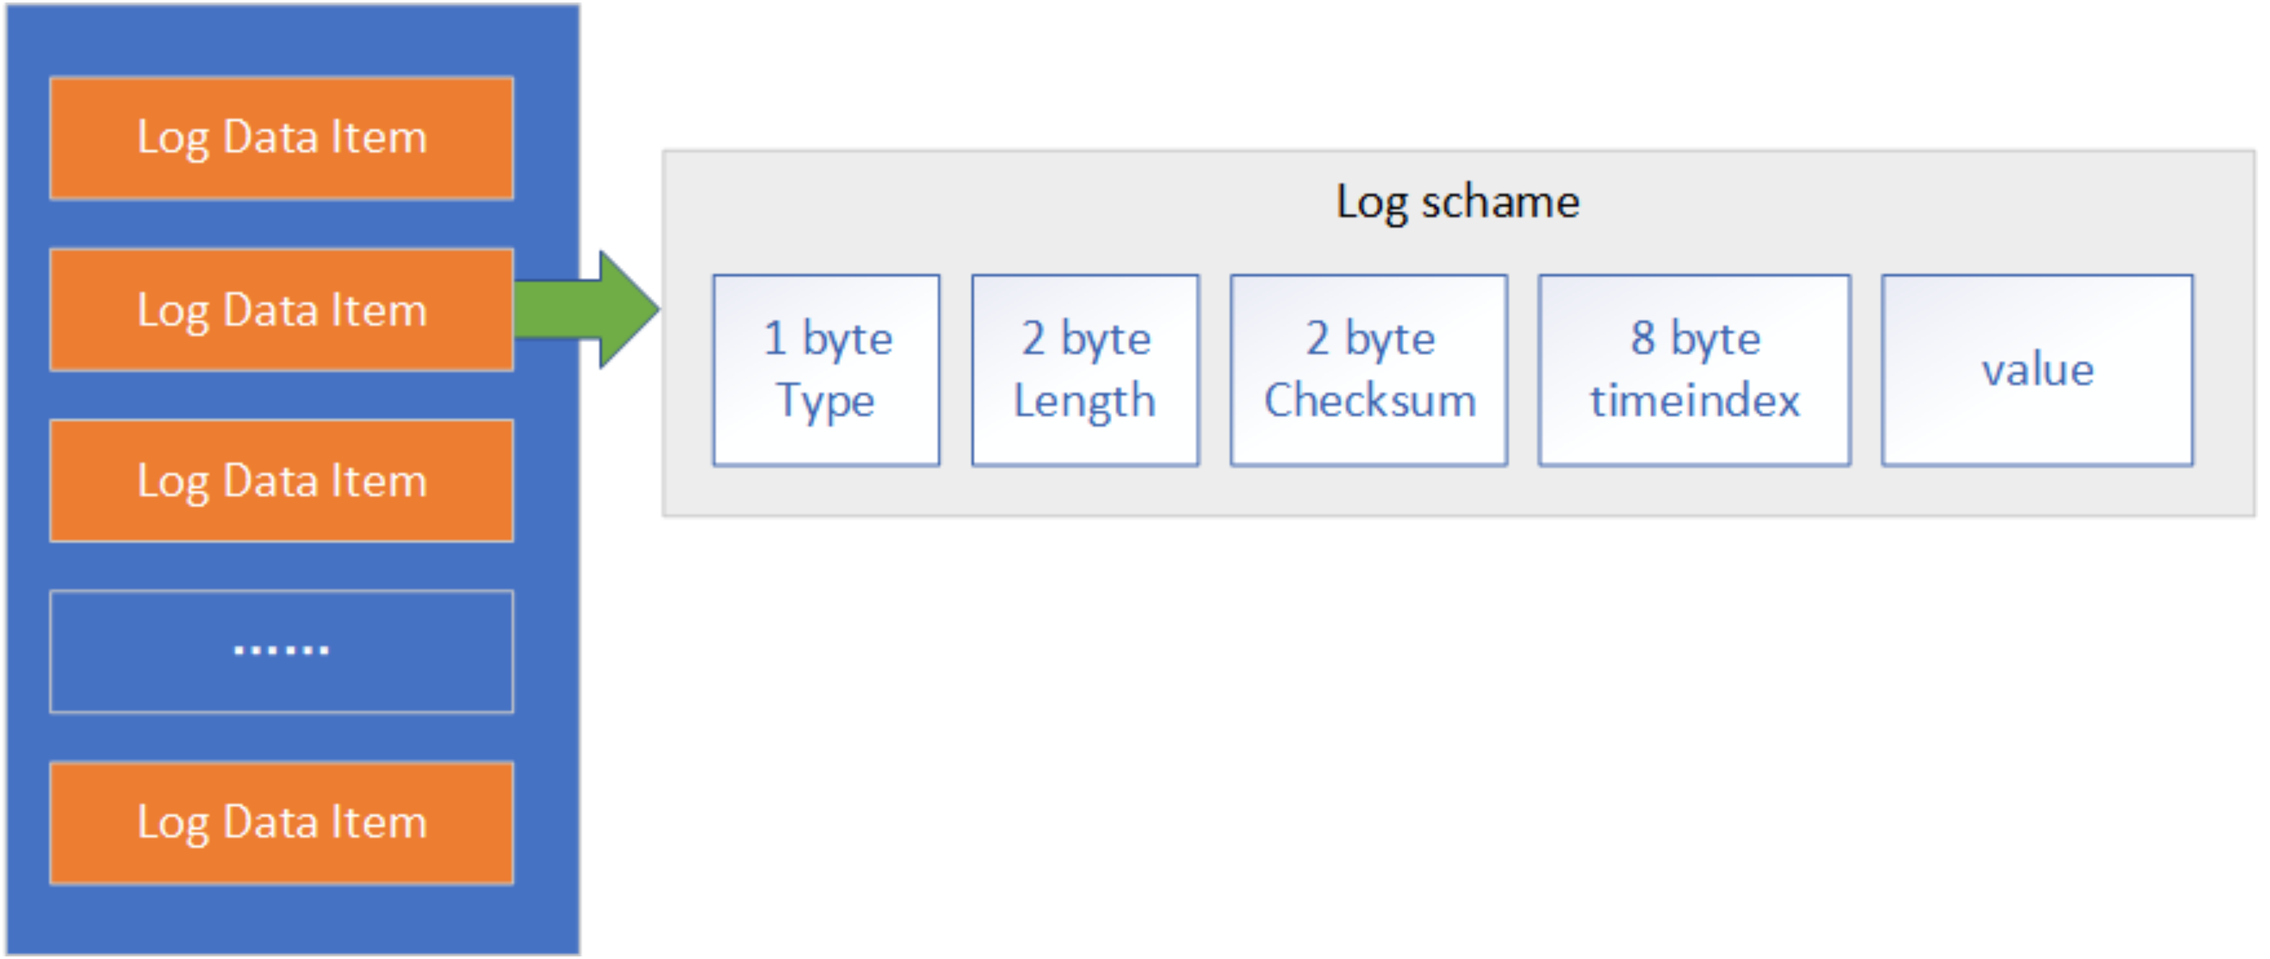
Log Data Item
Log Data Item
Log Data Item
.....
Log Data Item
Log schame
1 byte Type
2 byte Length
2 byte Checksum
8 byte timeindex
value

数据存储文件设计

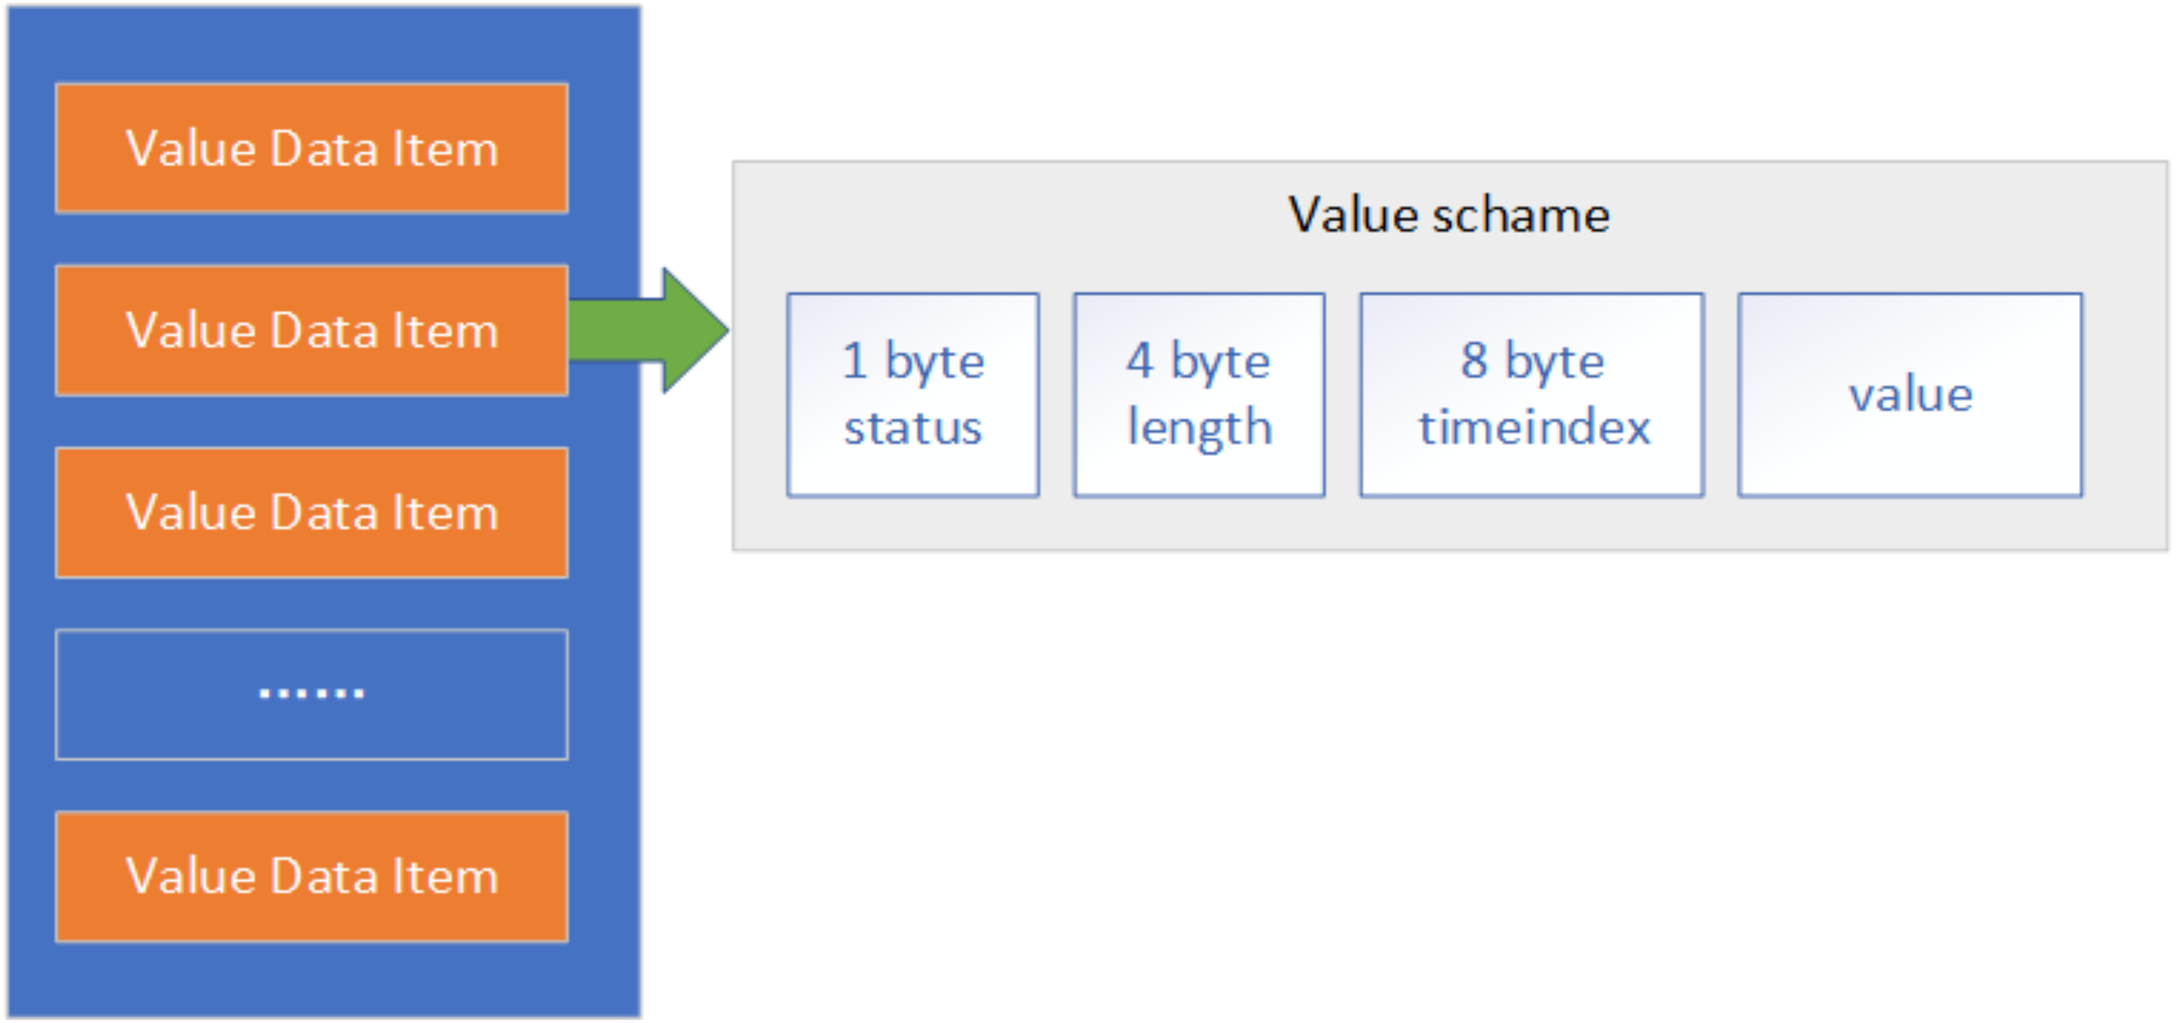
Value Data Item
Value Data Item
Value Data Item
.....
Value Data Item
Value schame
1 byte status
4 byte length
8 byte timeindex
value

数据索引文件设计

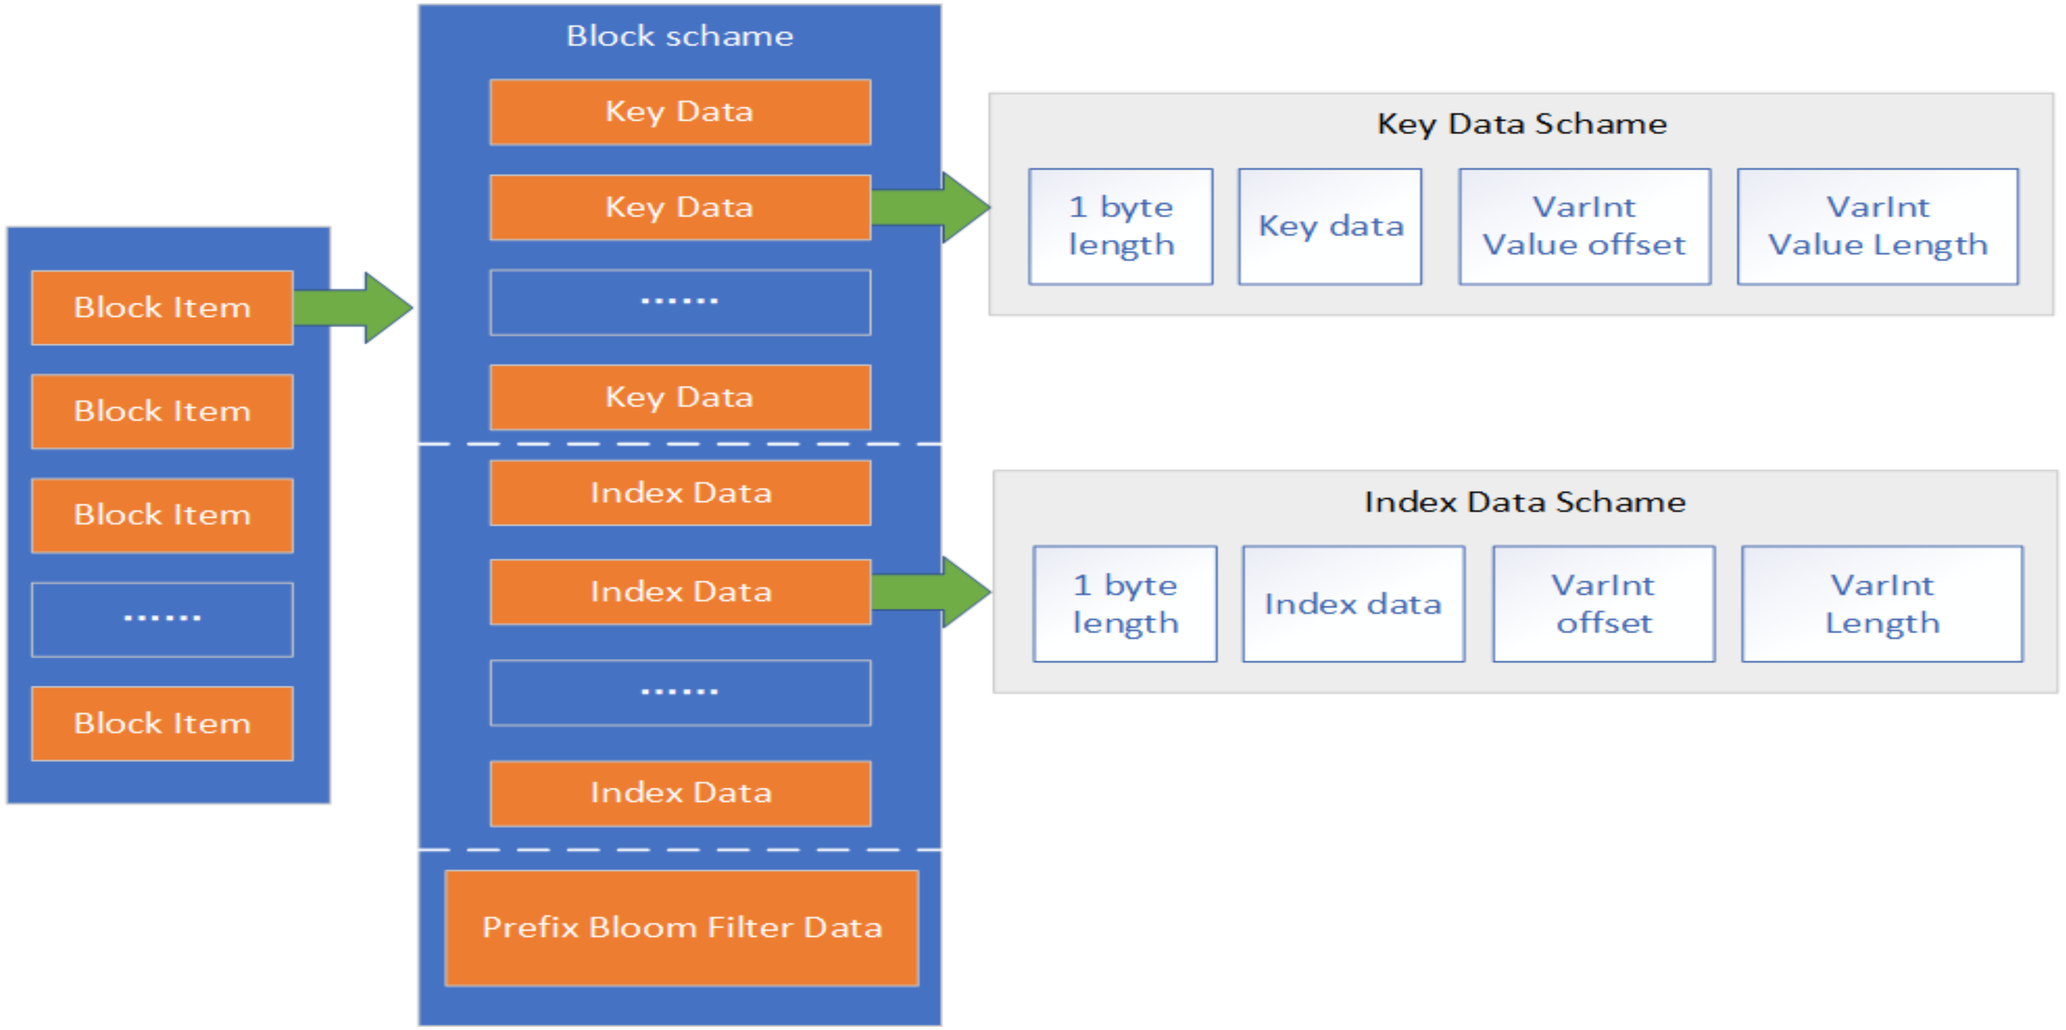
Block schame
Key Data
Key Data
.....
Key Data
Index Data
Index Data
.....
Index Data
Prefix Bloom Filter Data
Block Item
Block Item
Block Item
.....
Block Item
Key Data Schame
1 byte length
Key data
VarInt Value offset
VarInt Value Length
Index Data Schame
1 byte length
Index data
VarInt offset
VarInt Length

table信息文件设计

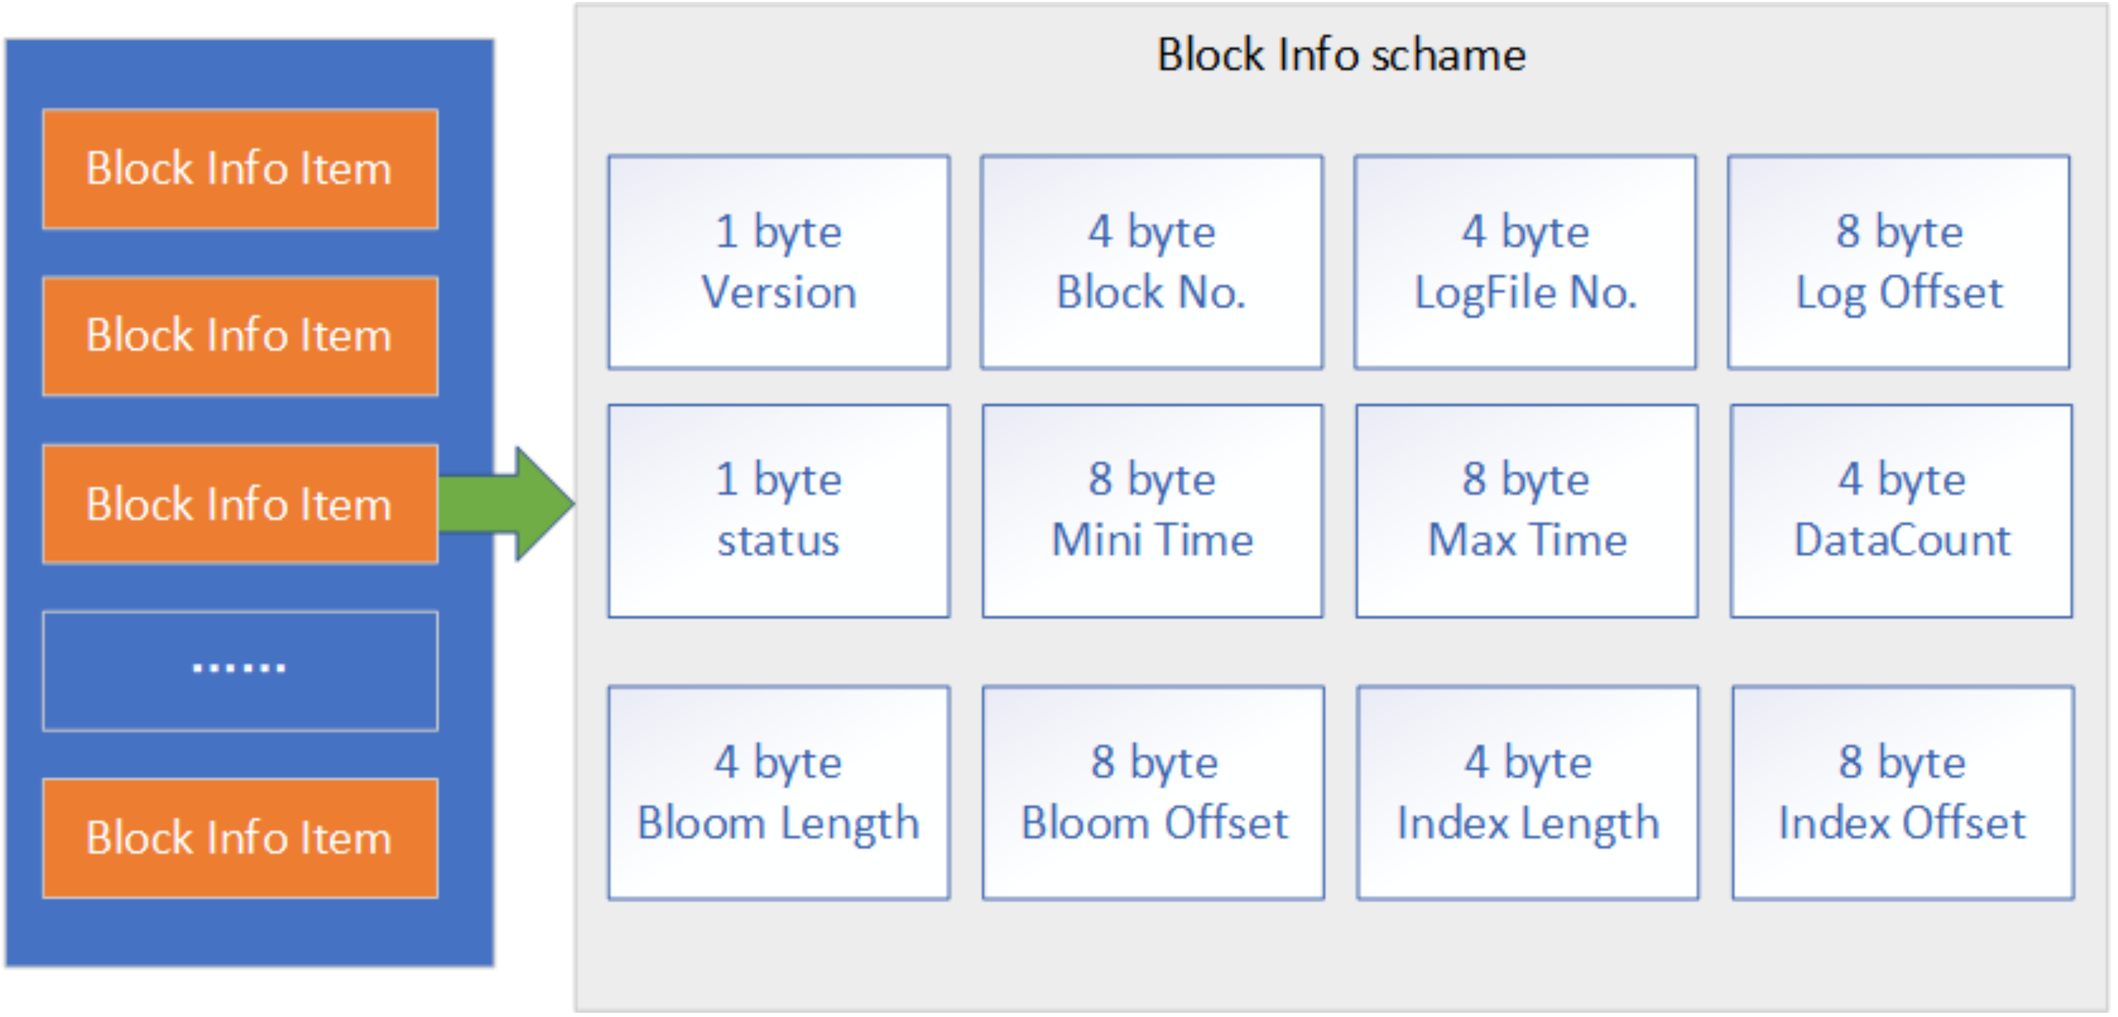

数据查询逻辑

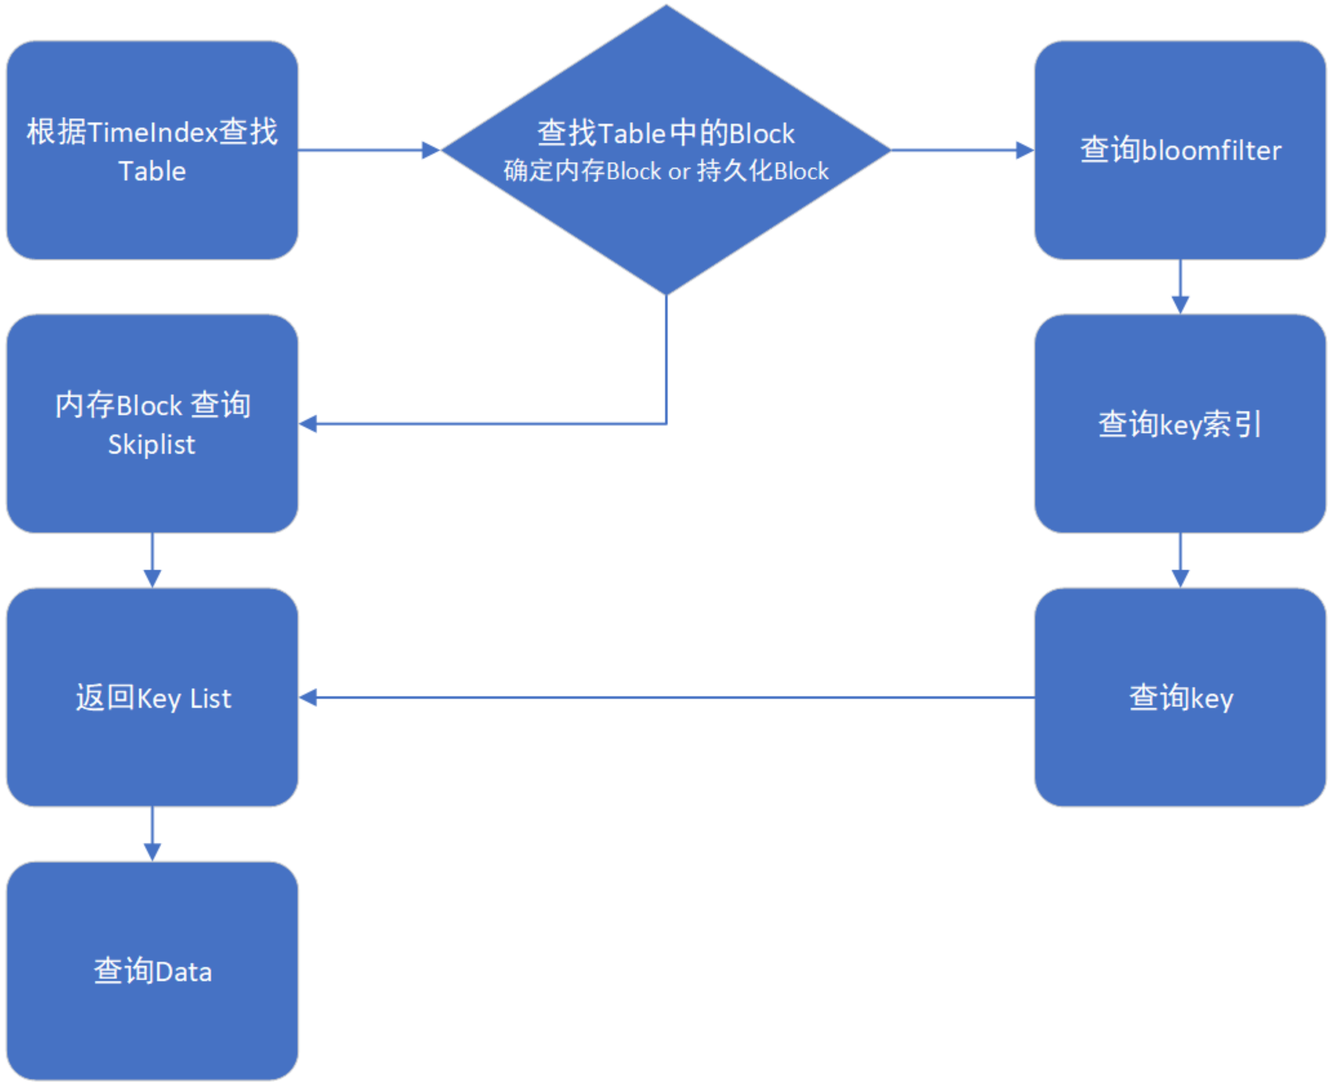
根据TimeIndex查找Table
查找Table中的Block
确定内存Block or 持久化Block
查询bloomfilter
内存Block 查询Skiplist
查询key索引
返回Key List
查询key
查询Data

内存优化篇

- 重写的SkipList，内存尽有Java中的 SkipList ¼
- 40亿数据索引，尽消耗400MB内存
- 实现内存对象分配器
- 实现 LRU 进阶的 LIRS 缓存

存储优化篇

- 索引数据前缀压缩
- 数值数据 VarInt 编码
- 业务数据 quicklz 压缩
- 数据写入采用双循环Buffer
- 重复数据引用写入

性能数据指标

写入速率测试		
数据量	耗时（毫秒）	速率（条/秒）
1,000,000	1,562	640,205
5,000,000	7,584	659,283
10,000,000	15,393	649,646
50,000,000	76,740	651,551
100,000,000	152,027	657,778
读取速率测试		
数据量	耗时（毫秒）	速率（条/秒）
1,000,000	3,483	287,109
2,000,000	6,970	286,944
5,000,000	16,176	309,100
10,000,000	32,135	311,187

CPU：Intel i7 8550U 内存：16GB JVM 4GB 硬盘：PCIe SSD

服务端架构

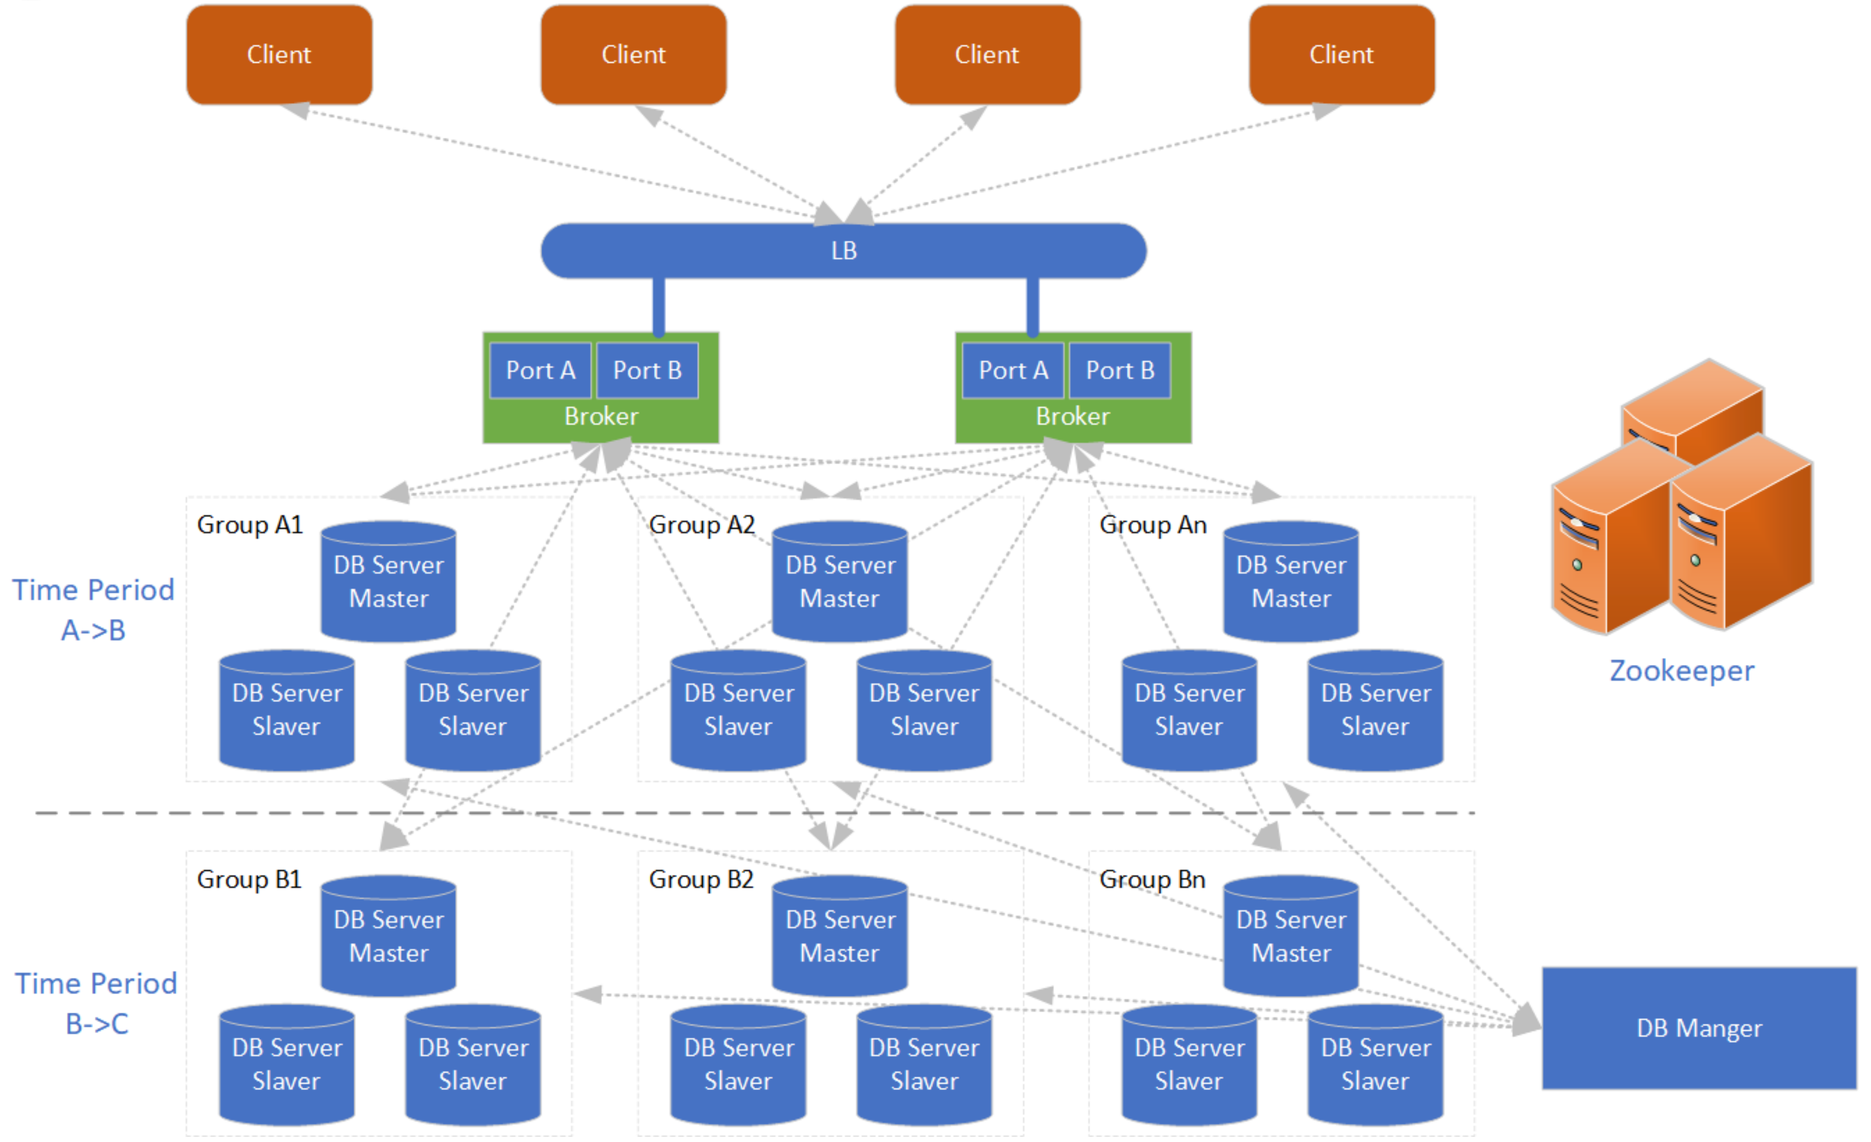
Client
Client
Client
Client
LB
Port A
Port B
Broker
Port A
Port B
Broker
Zookeeper
Time Period
A->B
Group A1
DB Server
Master
DB Server
Slaver
DB Server
Slaver
Group A2
DB Server
Master
DB Server
Slaver
DB Server
Slaver
Group An
DB Server
Master
DB Server
Slaver
DB Server
Slaver
Time Period
B->C
Group B1
DB Server
Master
DB Server
Slaver
DB Server
Slaver
Group B2
DB Server
Master
DB Server
Slaver
DB Server
Slaver
Group Bn
DB Server
Master
DB Server
Slaver
DB Server
Slaver
DB Manger

服务端特点

- ✓ 无数据迁移扩容
- ✓ 自动主从切换
- ✓ 异步长连接客户端
- ✓ 多协议适配（MQTT、Websocket、HTTP2）

特别提示

- 数据存储引擎未来两个月会进行开源

安全、可控、高效、稳定

的企业即时通讯统一平台就是融云

感谢聆听

RONGCLOUD

- www.rongcloud.cn
- support@rongcloud.cn | 400 - 919 - 9066
- 北京市朝阳区北苑路北甲13号院1号楼 北辰泰岳大厦 14层

THANKS!